
採用課題

CIFAR-10の画像分類

上智大学情報理工学科3年
浜口 創

アジェンダ

01

実験結果

02

改善施策

03

次に試すべき
改善施策

04

再現性・環境整備

01

実験結果

```
▼ Summary metrics: {} 10 keys
acc: 0.844103991985321

► confusion_matrix: {} 7 keys
epoch: 15

loss: 0.44102566734868653

▼ Misclassified Examples: {} 1 key
_type: "images/separated"

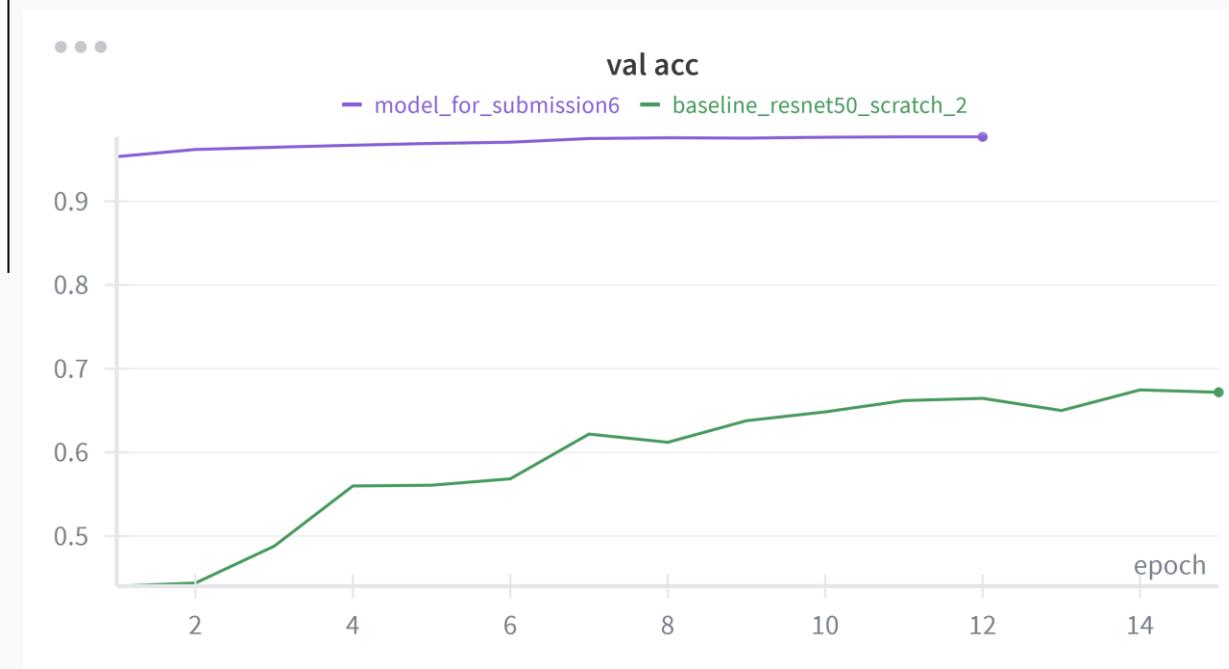
val acc: 0.6717486381530762
val f1: 0.673121233306793
val loss: 1.0872976273298265
val precision: 0.6788139369028423
val recall: 0.6734
```

実験設定

- データセット : CIFAR-10
- モデル : ResNet50
- 評価指標 : 左図の指標、学習曲線・混同行列・誤分類サンプル
- 再現性 : random/numpy/torchのseed固定 (cuDNN設定含む)

4つの改善施策で精度 + 30%

CIFAR-10に対してResNet50の分類モデルを実装し、改善施策を比較した。



(W&Bから出力)
ベースラインモデルと最終モデルの
学習直線の比較

- 転移学習（全層FT）・
スケジューラーを導入
- 正則化とデータ拡張で、
過学習を抑え汎化性能を改善
- 最終的に、Val Accが
67.2%→97.7%に向上

02

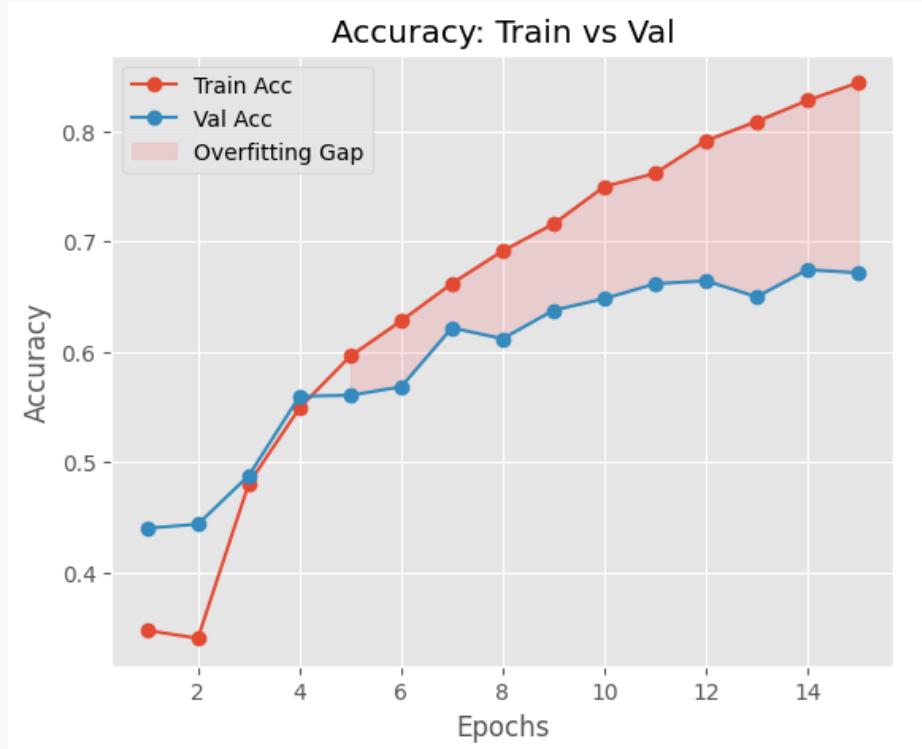
改善施策

ベースラインモデルの作成

条件

- データ拡張: 正規化のみ
- Optimizer: Adam
- LR: 0.001
- Epoch : 15
- Batch size : 512

結果



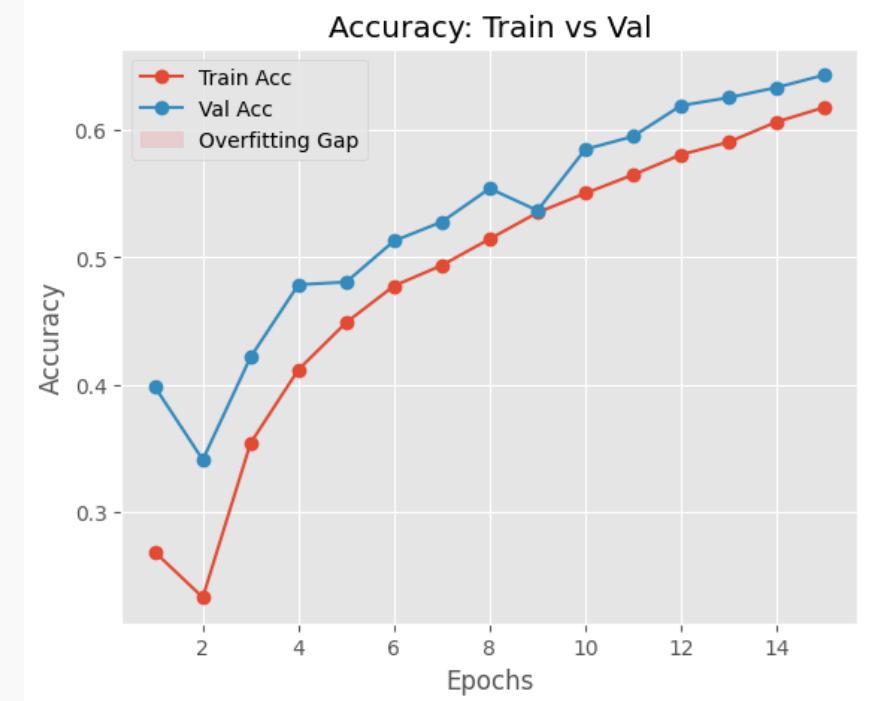
上記のグラフから過学習が発生している可能性があると考えた。

過学習の抑制実験

変更点

- データ拡張:
flip/crop/colorjitterの追加
- 正則化(Weight Decay) : $1e-4$

結果



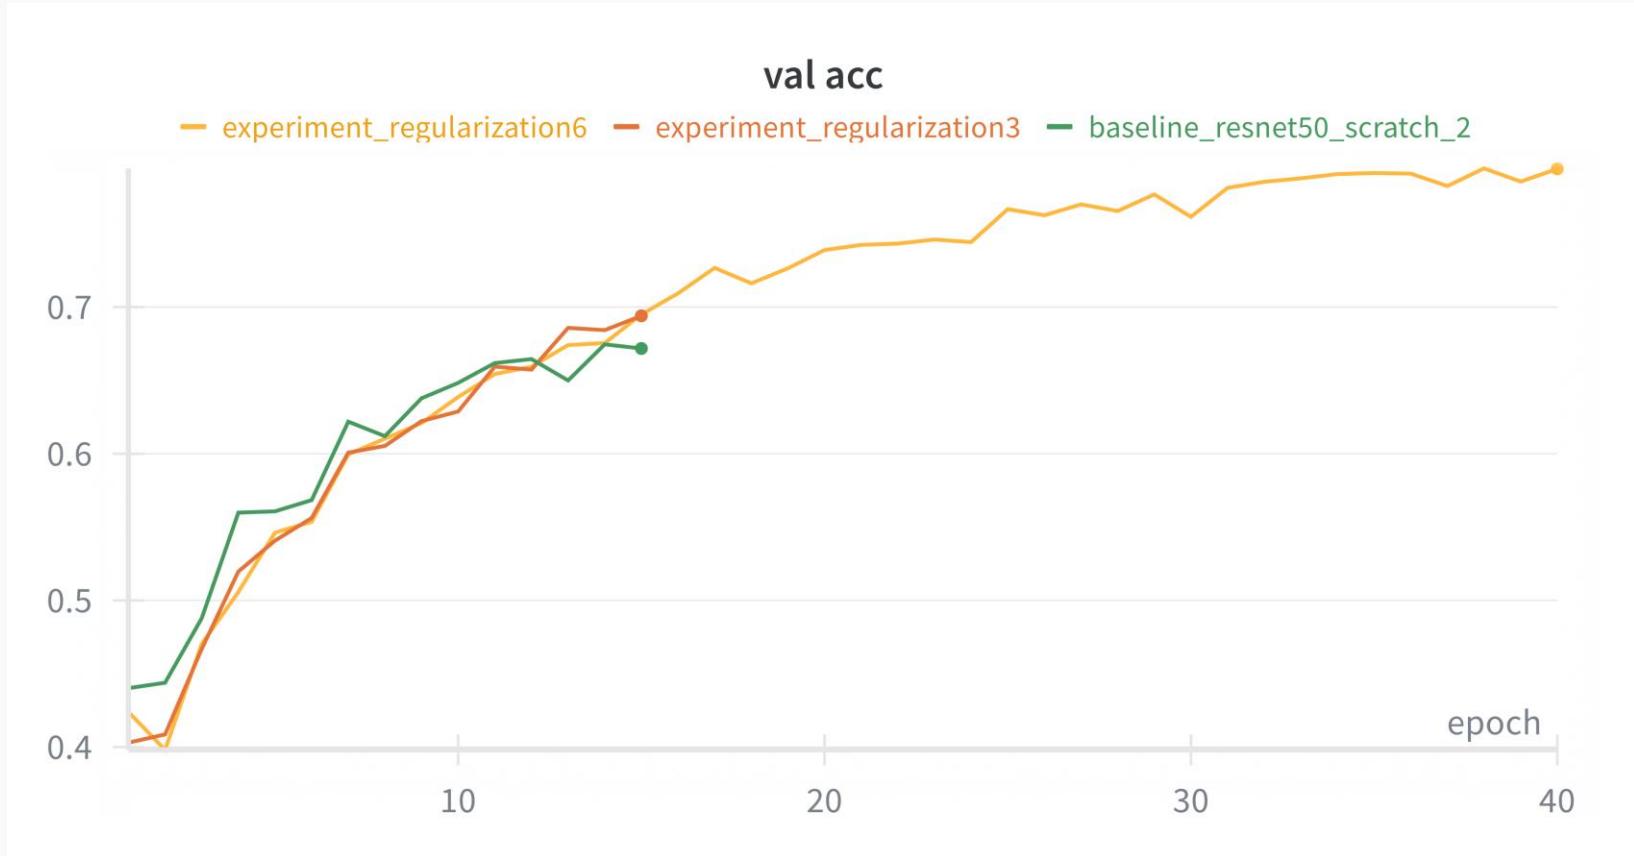
学習データの正解率とバリデーションデータの正解率を近づけることには成功。

過学習抑制実験の結果2



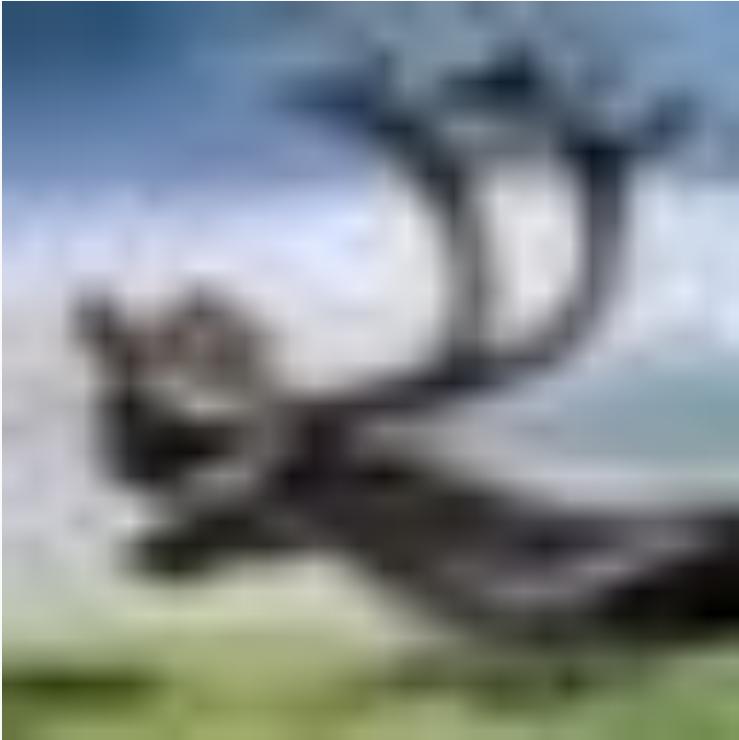
val lossは良くなっているが、汎化性能はそこまで上がりなかつた。
データ拡張を緩めるなどもしたが、val accはほとんど一定。

過学習抑制実験の結果2

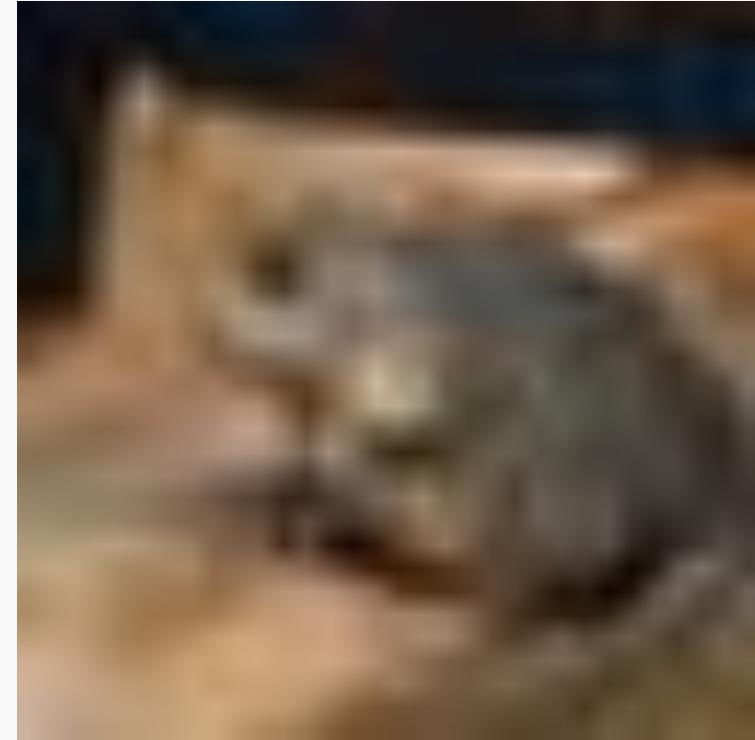


40エポックほどで頭打ちに見える。

誤分類サンプルを可視化



予想 : plane, 正解 : deer



予想 : cat, 正解 : frog

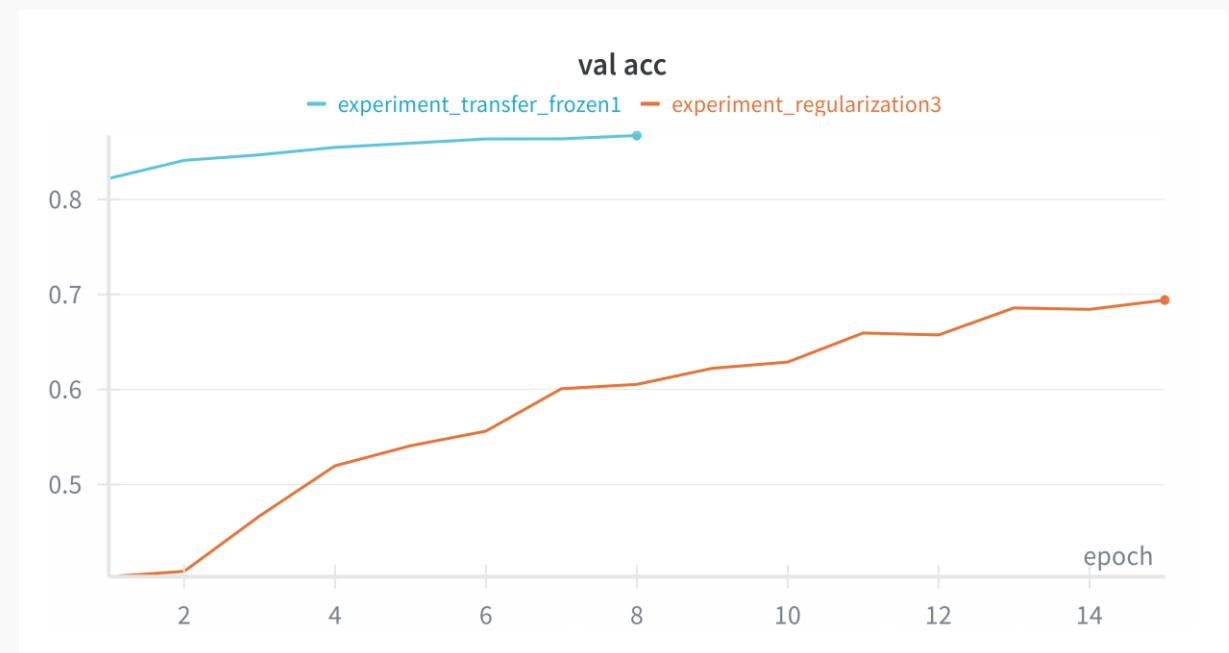
背景であったり、全般的な色であったり、**霧囲気**で判別しているのでは？

転移学習(全層凍結)

よって、解像度の良いImageNetで学習したResNetの重みを用いることで、
より被写体の特徴を抽出して推論できることを期待して、転移学習を導入する。

変更点

- 事前学習済みResNetの重みを用いる
- ImageNetの色平均で正規化
- 画像をresizeする。
 $32 \times 32 \rightarrow 224 \times 224$



時間がかかるのに驚く

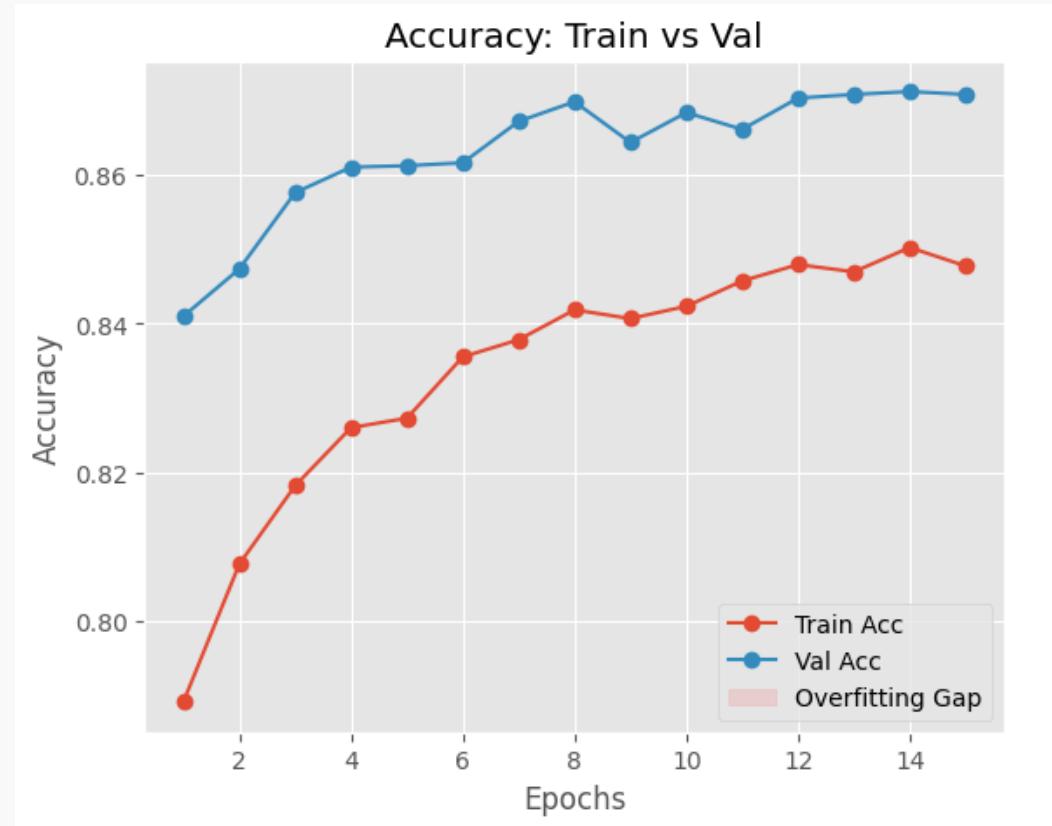
Udemyのチュートリアルでは全層凍結の転移学習が一瞬で終わっていた。
逆伝搬以外にも順伝搬に時間がかかるのを把握していなかった。

改善施策

- これはCPUでデータ拡張しているのが原因だと考えた。（特にresize）
- GPUでデータ拡張をするように変更。
- また、L4GPUは余裕があったので、バッチサイズも増やす。

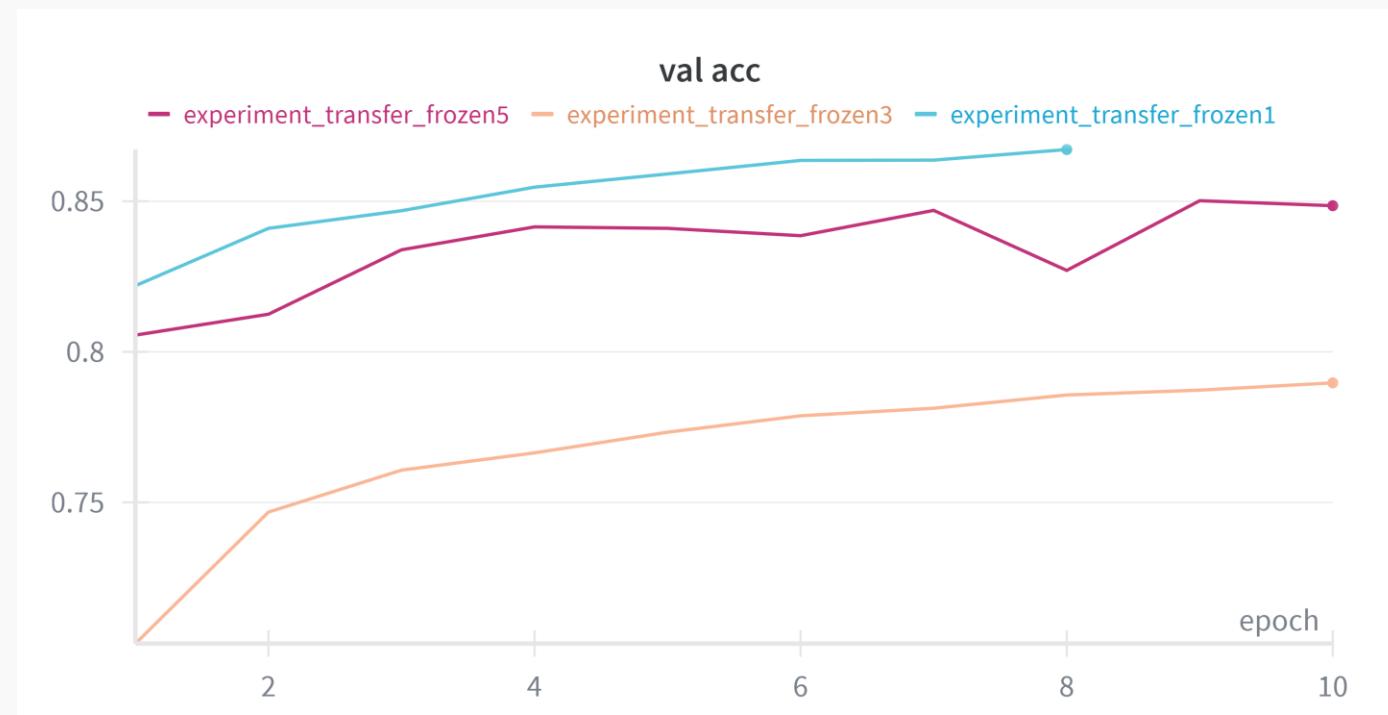
Val accの方が高い

- 強いデータ拡張によって、学習データが難しくなってしまっている可能性
- データ拡張を緩くしてみる



精度が下がる

- バッチサイズはあまり精度に関係ないと考えていたが、512にするとかなり精度が落ちた。
- また、データ拡張を強めるのも逆効果になってしまった。



転移学習(全層FT)

学習済みResNetは細かい特徴に対して反応できるようになっている

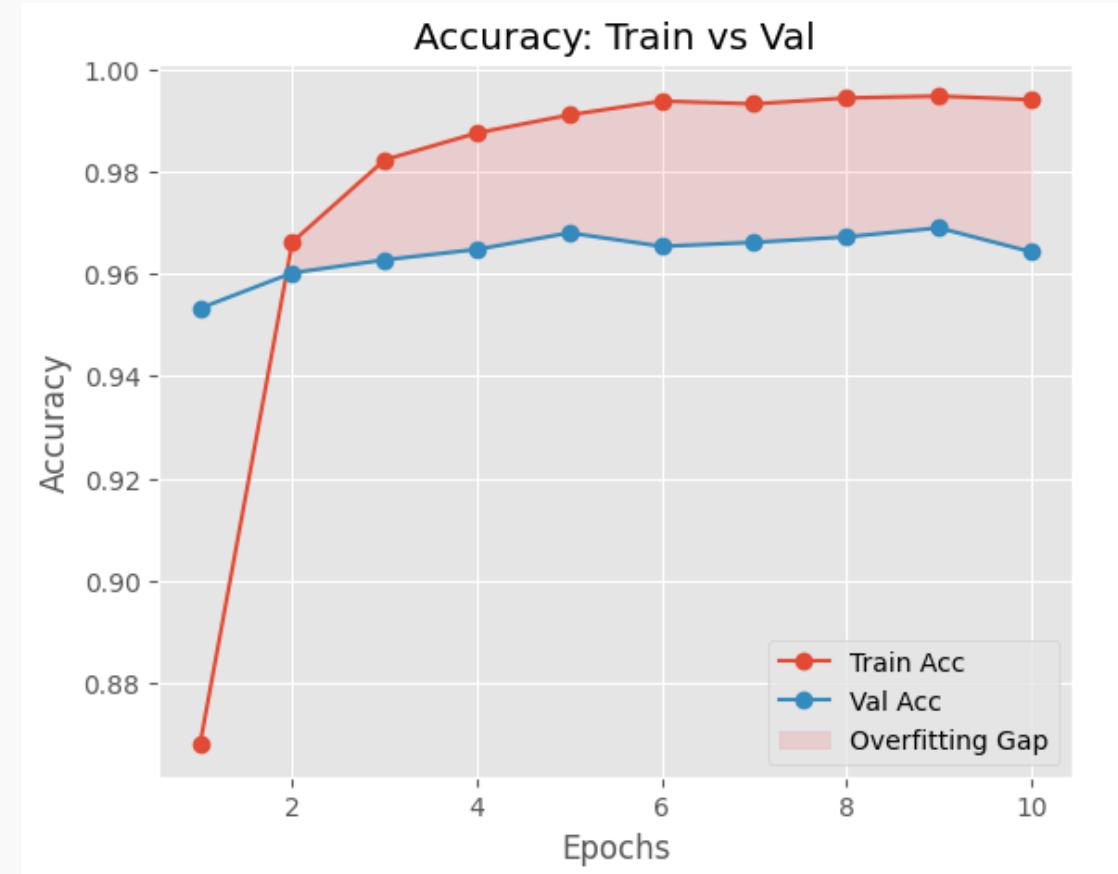
しかし、CIFAR-10の画像は解像度が非常に粗く、

細かい情報が抜け落ちていて、この分類に対して無駄が多いのではないか

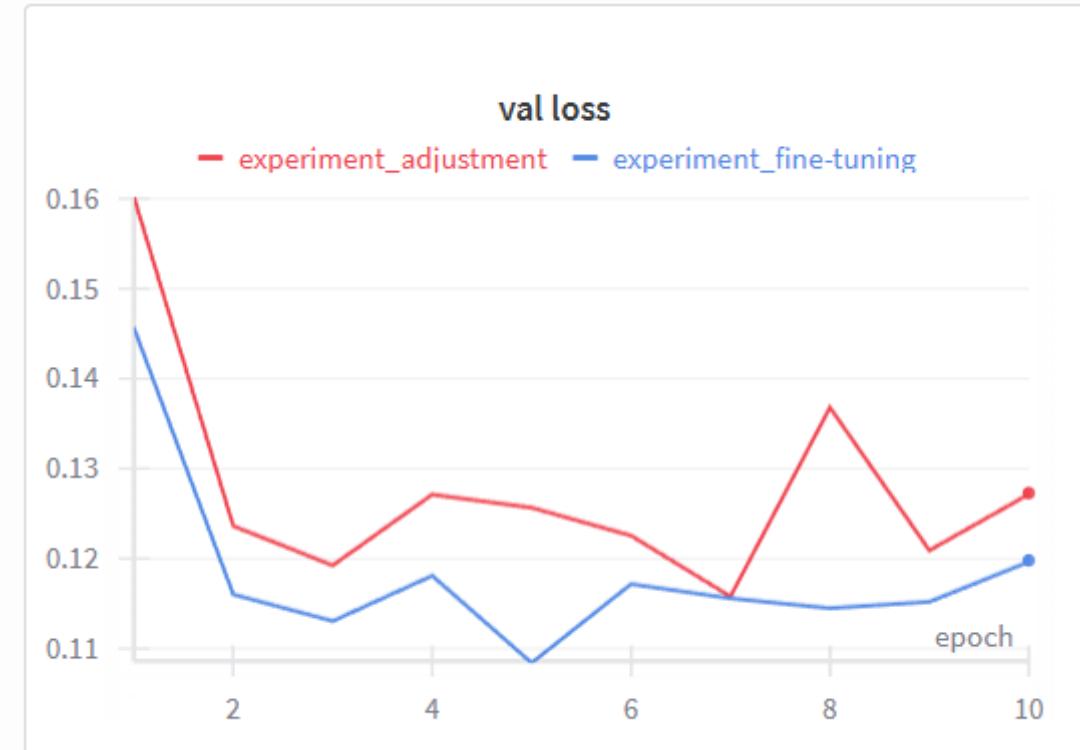
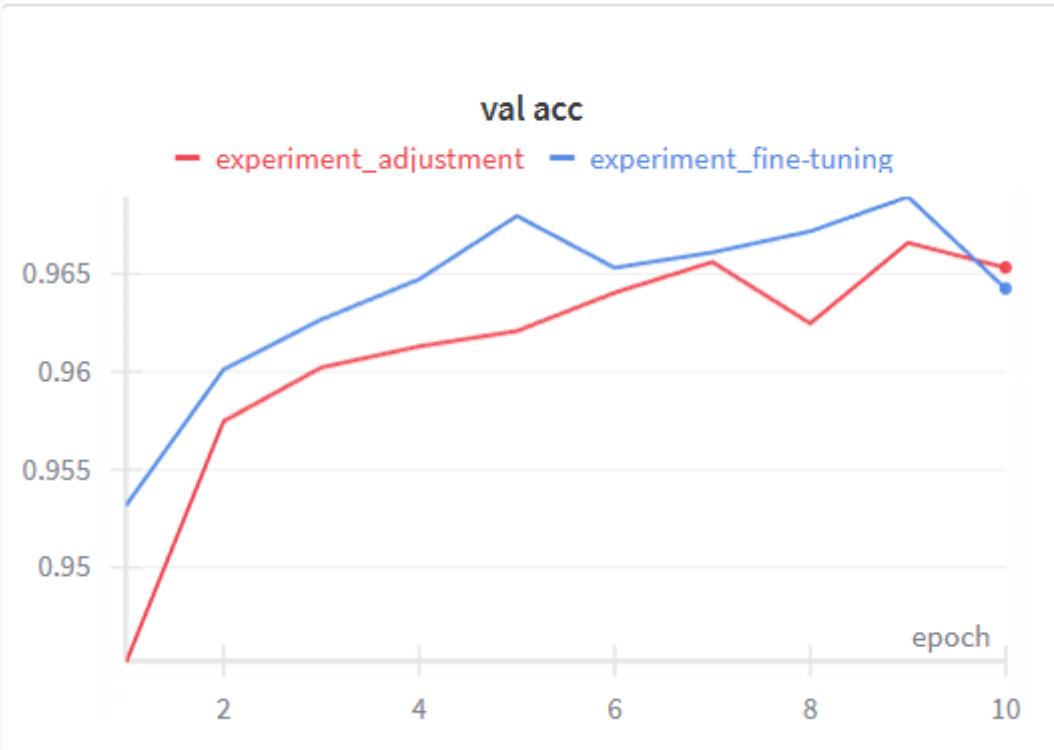
- CIFAR-10の分類で求められるのは、シルエットやパーツなどの情報を読み取ること。
- Fine-tuningすることで、学習済みResNetがCIFAR-10に適したモデルとなるのでは。

全層FTの結果

- 非常に良い精度が出た
- 学習データのaccがほぼ100%
- データ拡張を強くすることでより汎化性能が上がるのではないか？



実験結果



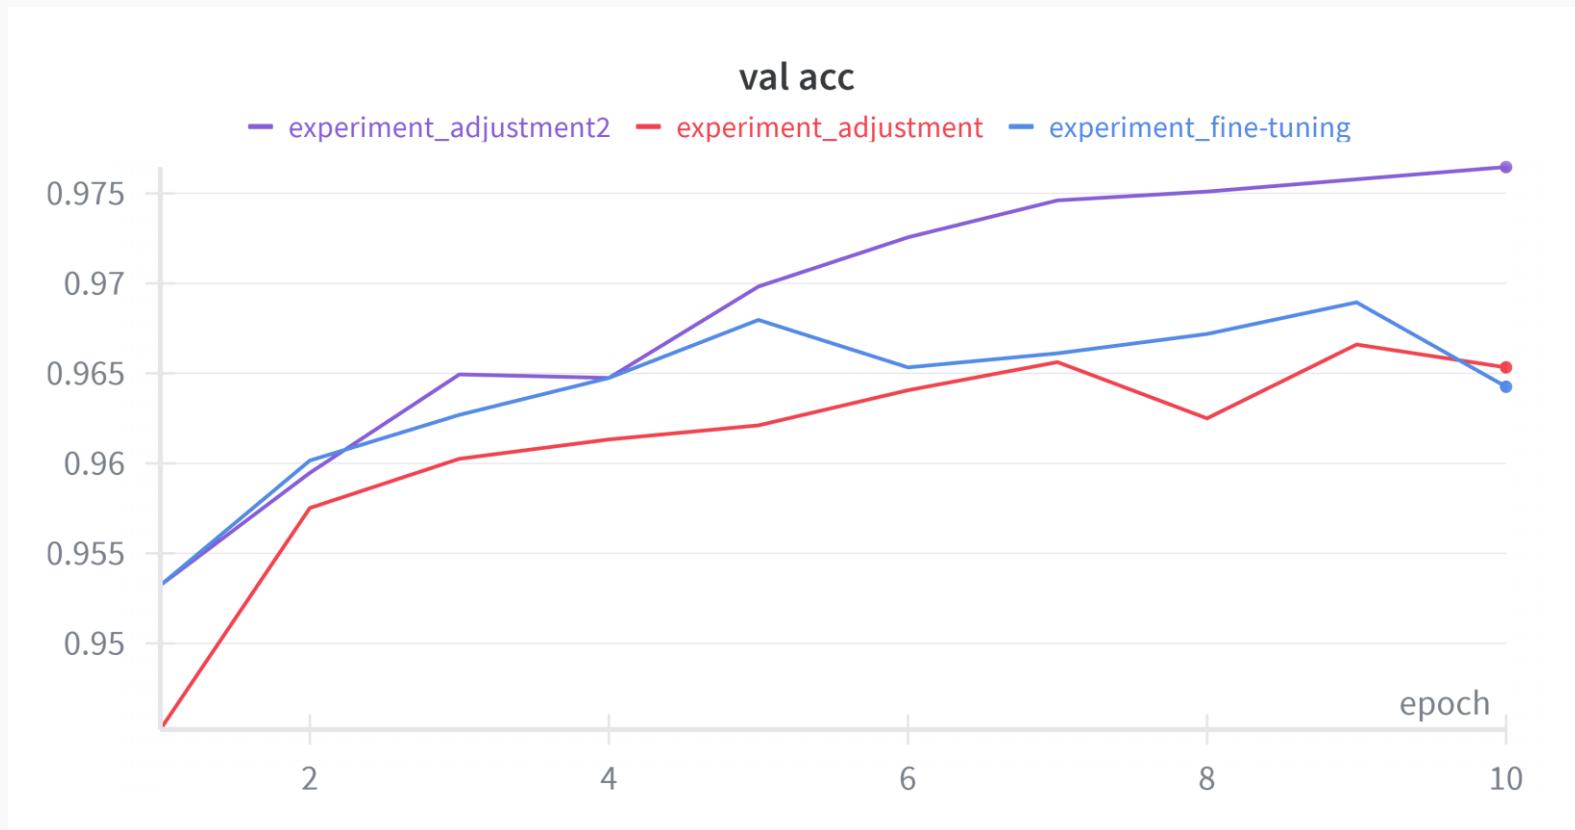
汎化性能はほとんど上がらず、lossも上がってしまう。

スケジューラーの導入

データ拡張やWDの値はいったん戻す

- 全層ファインチューニングは精度がいい。
- 学習後半で不安定になっている
- LRを後半で小さくすることによって、収束しやすいようにする。

スケジューラー実験結果



精度の大幅な更新に成功！

Two-Stage training

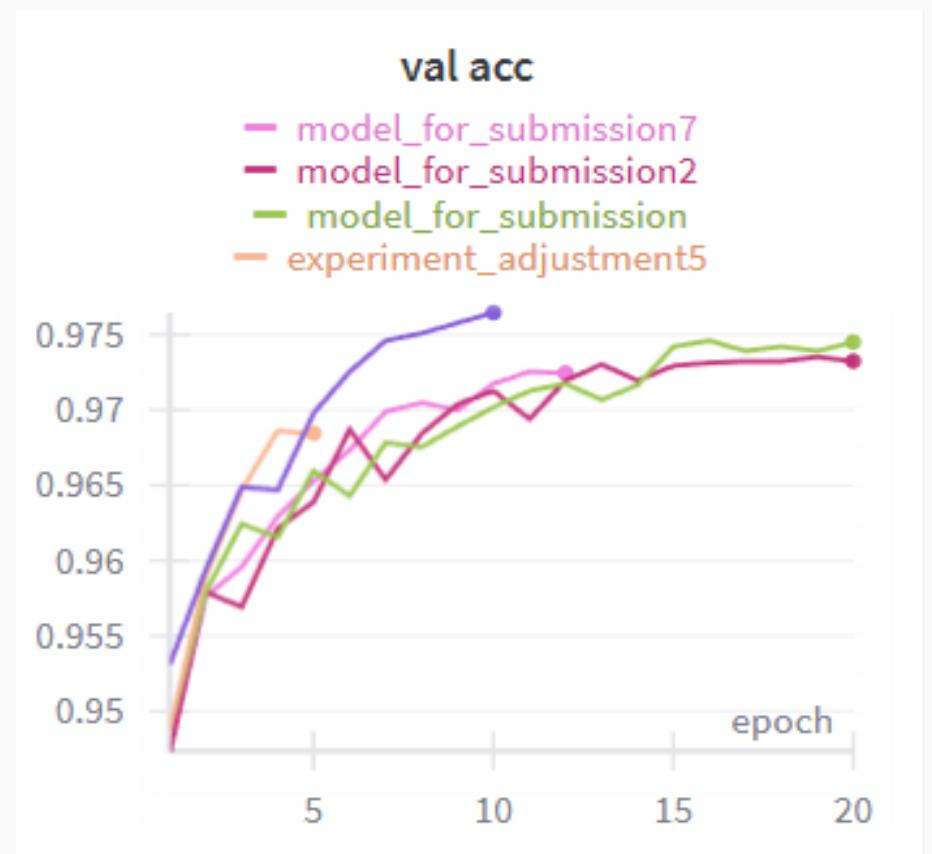
全層凍結で得た重みをベースとして、FTを行う手法

- 序盤で逆伝播する際にfc層の重みがランダムであると、大きく重みがずれてしまう可能性がある。
- 全層凍結モデルの重みを使って全層FTを行う。
- 初期の最適化が安定し、発散・過学習を抑えやすい

実験結果

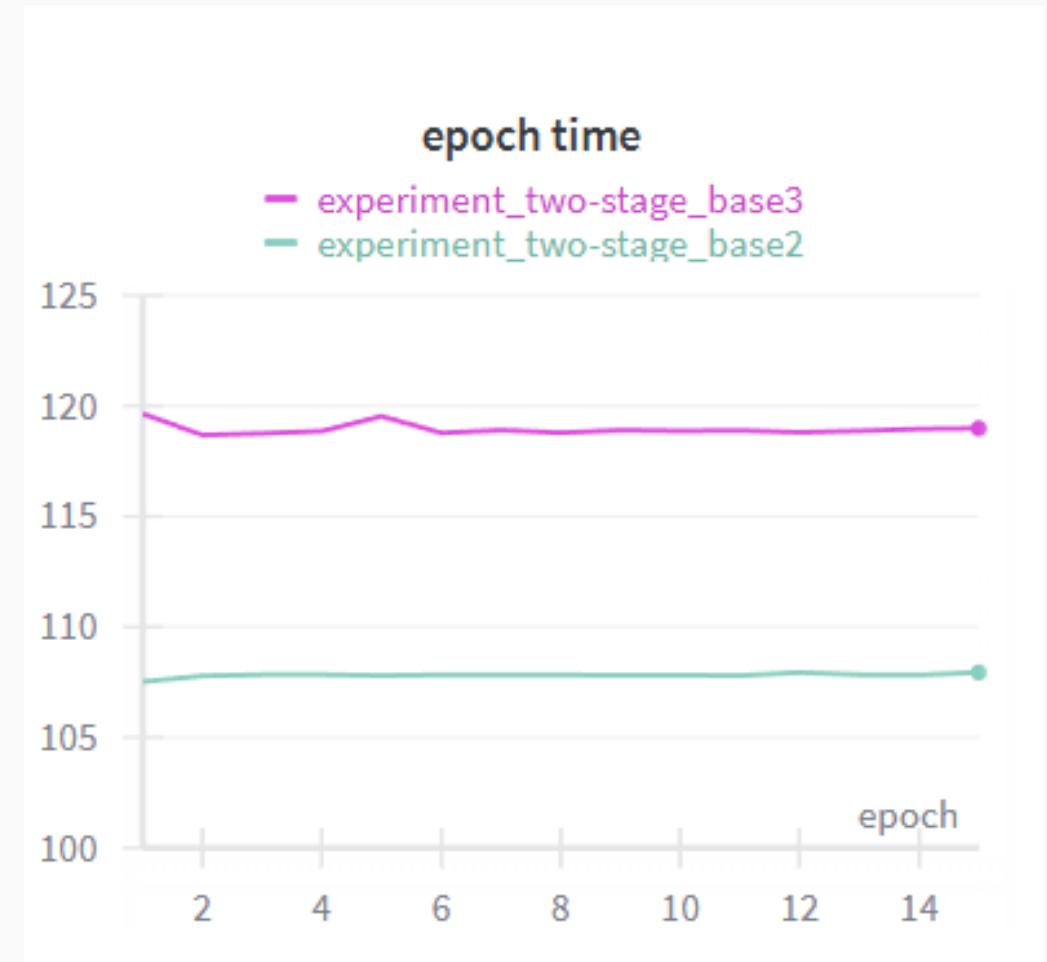
先の結果がとても良いものであった。

- 施策自体は悪くないはず
- 逆に初期の探索のおかげでより良い精度にたどり着けたのでは
- 再現性は担保しているため、今回凍結モデルを用いずに進める

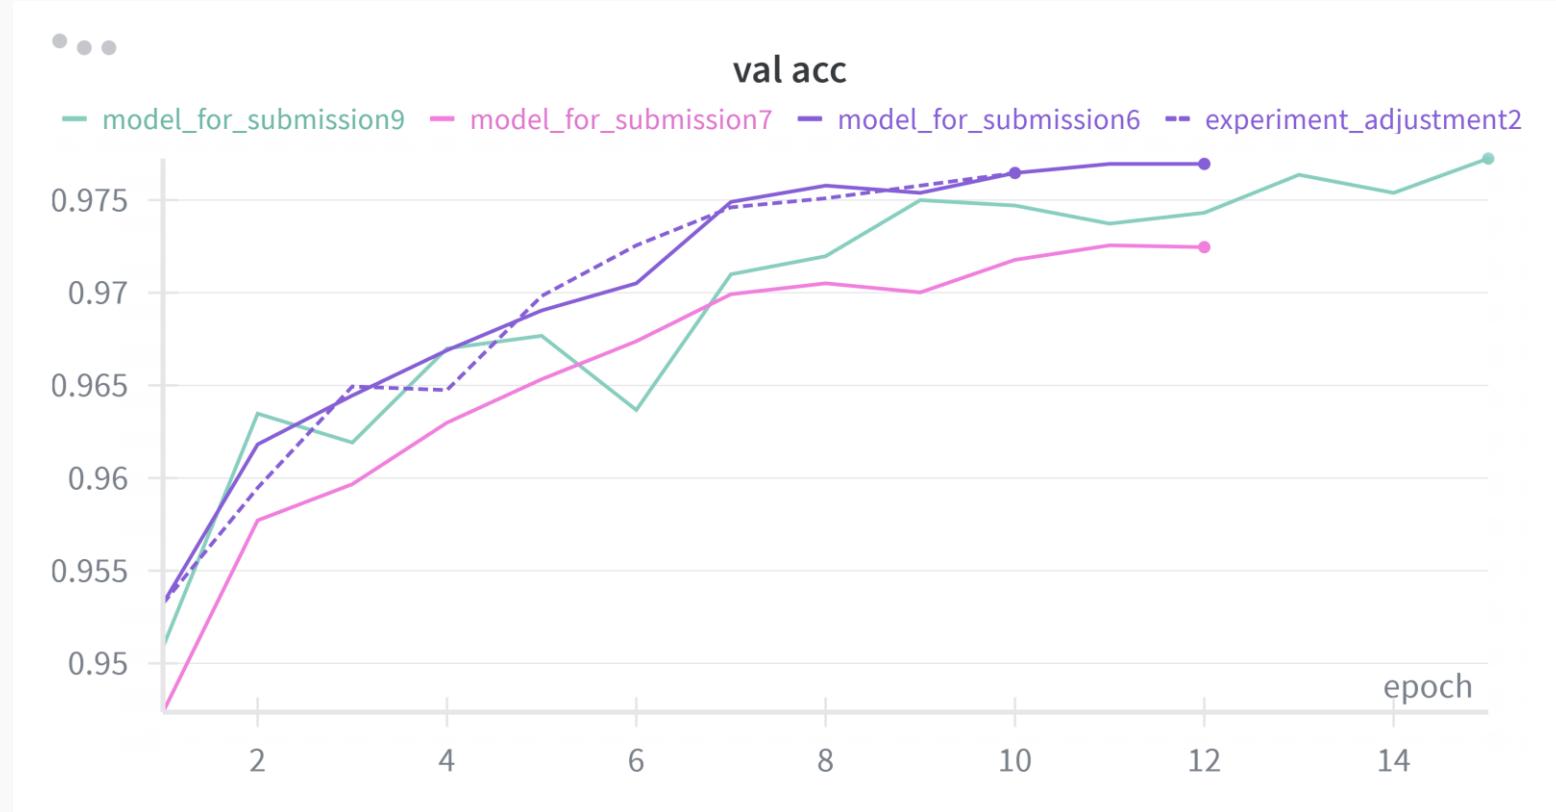


CPU/GPU前処理: 実行時間差検証

- Two-stageモデルのベースとなる凍結モデルを作成する際に実行時間を測定した。
- 確実にGPU前処理の方が短いものの、各エポック10秒ほどの差しかなかった。
- CPU前処理の方が精度が出やすい傾向があるので、最終的にはそちらを用いる。



エポック数など微調整を行い、最終モデル



CPU前処理・エポック数15の全層FTモデルが**97.7%**で最高

03

次に試すべき 改善施策

You can enter a subtitle here if you need it

考えられる改善施策

1. ベースとなるモデルの変更

Efficient Net, ViTなど

2. 複雑なデータ拡張

Mixup, CutMixなど

3. オプティマイザの変更

AdamW, SGDなど

4. 浅い層のみ凍結したFT

汎用的な部分は残して、細かい部分に注目する 中間層以降をFT

04

再現性・環境整備

再現性

- 学習や推論に使うファイルをすべてGitHubに追加
 - 。 リポジトリのクローンを行うことで、同様の環境
- Seedの値を42に固定。(random/numpy/torch)
- cuDNNで計算の順番やアルゴリズムを固定化し、再現性を確保。
- requirements.txtを用意し、環境構築をスムーズに行える。

環境整備

- GitHubを見やすいように整備し、誰もがすぐに学習や推論に取り掛かれるようにした。

学習実行手順

- デフォルト実行

```
python train.py
```



- W&Bにログを記録したい場合（任意）

```
# W&Bにログイン  
wandb login  
  
python train.py --use_wandb  
  
# --log_imagesとすると誤分類画像が毎エポック記録されます。必要な場合はご使用ください。
```



- ハイパーパラメータの変更

```
#例  
python train.py --epochs 12 --batch_size 64 --seed 42
```



Out of Memoryになってしまった場合は、batch_sizeを32などに下げてお試しください。

環境整備

- argparseで、`--epochs`などコマンドを入れることで、ハイパーパラメータの調整やW&Bへの記録の有無などを選択可能にし、様々な用途に対してもすぐに試せるようにした。
- また、GPUの有無やOSの違いなど、実行環境の違いによってエラーが起きないように配慮を行った。

以上です
ありがとうございました！
